

Modelo para el histórico desde el año 2000 de la estimación del número de defunciones semanales en Palencia

Eric Jimenez Barril - 1599092
Universitat Autònoma de Barcelona
Series Temporales

(Dated: December 7, 2023)

I. ADQUISICIÓN DE LOS DATOS.

En primer lugar, descargamos los datos del histórico desde el año 2000 hasta la semana 44 del año 2023 de la estimación del número de defunciones total semanales de la provincia de Palencia. [1].

A. Lectura de los datos.

Como podemos ver en la Figura 1, los datos vienen dados por un *data frame* de 6 columnas de las cuales nos interesan solo las dos últimas, ya que son las que indican el periodo y el total de defunciones estimadas.

	Total	Nacional	Provincias	Tipo	de	dato	Periodo	Total.1
1	Total	Nacional	34	Palencia	Dato	base	2023SM44	27
2	Total	Nacional	34	Palencia	Dato	base	2023SM43	46
3	Total	Nacional	34	Palencia	Dato	base	2023SM42	53
4	Total	Nacional	34	Palencia	Dato	base	2023SM41	33
5	Total	Nacional	34	Palencia	Dato	base	2023SM40	31
6	Total	Nacional	34	Palencia	Dato	base	2023SM39	42

FIG. 1: Datos dados por el INE para la estimación de defunciones en Palencia por semanas entre la primera semana del 2000 y la semana 44 de 2023.

B. Limpieza de los datos.

Los datos no contienen valores faltantes, y queremos hacer un modelo de predicción para el número de defunciones, por lo que el único preprocesado a los datos que tenemos que hacer es invertirlos, pues empiezan a final de 2023 y van en orden descendiente de fecha.

Como podemos apreciar en la Tabla I no todos los años tienen las mismas semanas, por lo que definimos una nueva serie *Total* que va del año 2010 al año 2022 y coge las primeras 52 semanas de cada año.

2000	2001	2002	2003	2004	2005	2006	2007
52	52	52	52	53	52	52	52
2008	2009	2010	2011	2012	2013	2014	2015
52	53	52	52	52	52	52	53
2016	2017	2018	2019	2020	2021	2022	2023
52	52	52	52	53	52	52	44

TABLE I: Semanas por año

II. VISUALIZACIÓN DE DATOS.

Con tal de visualizar la serie *Total*, la dibujamos en la Figura 2 junto a su media y su media móvil.




FIG. 2: Número de defunciones por semana en Palencia entre 2010 y 2022 junto a la media y la media móvil.

Podemos observar que la media móvil no se ajusta del todo a la media, lo que indica que la serie tiene tendencia y además no es una recta, por lo que tiene componente estacional. Además, es claro que la varianza de la serie no es constante (picos que resaltan sobre la media).

III. DESCOMPOSICIÓN DE LA SERIE TEMPORAL.

A. Estudio de la tendencia.

Si la serie tiene tendencia, fijándonos en la Figura 2 aparentemente será creciente. Creando una regresión lineal respecto al tiempo, obtenemos el modelo de Ecuación 1

$$\text{Defunciones en semana } t = 38.26930 + 0.00916t \quad (1)$$

donde $t \in \{1, \dots, 676\}$

Observamos que la media de los datos es 41.36982 y el *intercept* de la regresión es 38.26930; en caso de no haber tendencia, la media y el *intercept* coincidirían. Además, obtenemos un p -valor de 6.637×10^{-7} para el *test* con hipótesis nula que el coeficiente que acompaña a la t es 0, el cual es positivo. Por tanto con un 99.9% de confianza hay una tendencia creciente estadísticamente significativa.

B. Estudio de la estacionalidad.

Estudiemos ahora si tiene estacionalidad, que en caso de tener, tendría que ser anual, ya que la serie son datos semanales de diferentes años.

Como podemos ver en la Figura 3, los *box* no se ajustan a los mismos rangos de valores, por lo que parece haber una estacionalidad anual.




FIG. 3: `box.plot` de la serie `Total` con los datos agrupados por semanas.

Además, haciendo el truco basado en el *likelihood ratio test*, obtenemos un *p-valor* de 0, por lo que rechazamos la hipótesis nula de que el modelo con componente estacional y sin ella sean iguales, es decir, la serie tiene componente estacional anual.

Por último, si observamos en la Figura 4 la componente estacional de la función `decompose()`, notamos que los valores de la componente estacional tienen un rango entre -10 y ~ 15 , lo que representa aproximadamente un 30% de la varianza global de los datos.




FIG. 4: Componente estacional de la serie `Total` según la función `decompose()`.

C. Estudio de la serie diferenciada

Con tal de tratar de eliminar la tendencia y la estacionalidad, creamos la serie `Total.diff1.52` que podemos visualizar en la Figura 5, que es la serie `Total` diferenciada por la primera diferencia (para eliminar tendencia) y después por la diferencia 52 (para la estacionalidad).

Realizando el mismo procedimiento que con la serie `Total`, obtenemos el `box.plot` de la Figura 6 y la gráfica




FIG. 5: Serie `Total` diferenciada por la primera diferencia y después por la de orden 52.

de la Figura 7 de la función `decompose()`. Observamos como los *boxplots* en la Figura 6 están bastante alineados y la variabilidad de la Figura 7 es $\sim 15\%$ de la variabilidad de la serie. Además, haciendo la prueba con el truco basado en el *likelihood ratio test* con las mismas hipótesis que antes, obtenemos un *p-valor* igual a 1, por lo que no tenemos evidencias para rechazar la hipótesis nula. Por tanto concluimos que la serie `Total.diff1.52` no tiene componente estacional estadísticamente significativa.




FIG. 6: `Box-plot` por semanas de la serie `Total.diff1.52`




FIG. 7: Componente estacional de la serie `Total.diff1.52` según la función `decompose()`

Ahora, haciendo el *Augmented Dickey-Fuller test* a la serie `Total.diff1.52`, que tiene como hipótesis

$$\begin{cases} H_0: \text{La serie tiene una raíz unitaria y no es estacionaria.} \\ H_1: \text{La serie no tiene raíces unitarias y es estacionaria.} \end{cases}$$

obtenemos un *p-valor* menor que 0.01, por lo que podemos rechazar la hipótesis nula y con un 99.9% de confianza, decir que la serie es estacionaria (tiene sentido tanto analíticamente, pues hemos diferenciado la serie para ello, como cualitativamente observando la Figura 5).

D. Estudio de la variable *COVID*.

Si añadimos una variable $C := COVID$ que represente un vector de unos entre las semanas de marzo de 2021 y todo 21, y el resto 0, al crear un modelo de regresión de la serie *Total* con respecto de la variable C , obtenemos el modelo de Ecuación 2

$$\text{Defunciones en semana } t = 40.585 + 5.707C \quad (2)$$

Haciendo un *test* de coeficientes para el coeficiente que acompaña a C , obtenemos un p -valor de 4.323×10^{-8} , por lo que la variable C es estadísticamente significativa para nuestros datos, es decir, el periodo donde empezó el C y tuvo más impacto, influye en nuestra serie.

IV. MODELADO Y PREDICCIÓN.

A. Propuesta de un modelo para la serie diferenciada según su EACF, ACF y PACF

En primer lugar, observando la EACF de la serie *Total_diff1_52* en la Figura 9 diríamos que el modelo para la serie es un MA(1), lo que coincide con lo que observamos en la Figura 8 pues la ACF únicamente tiene el *lag* 1 estadísticamente distinto de 0 y la PACF decae a 0 de forma exponencial. Por tanto en caso de tener que escoger un modelo para la serie *Total_diff1_52* basándonos en la EACF, ACF y PACF sería un MA(1).




FIG. 8: ACF y PACF de la serie *Total_diff1_52*.

AR/MA	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	x	x	o	o	o	x	o	o	o	o	x	x	x	o
1	x	x	o	o	o	x	o	o	o	o	o	x	x	o
2	x	x	o	o	o	x	o	o	o	o	o	o	x	o
3	x	x	o	x	o	x	o	o	o	o	o	o	x	o
4	x	x	x	x	o	o	o	o	o	o	o	o	x	o
5	x	x	x	x	o	x	o	o	o	o	o	o	x	o
6	x	x	x	x	o	x	x	o	o	o	o	o	x	o
7	x	x	x	x	o	x	o	o	o	o	o	o	x	o

FIG. 9: EACF de la serie *Total_diff1_52*.

B. Creación del primer modelo para la serie original.

Si creamos un modelo para la serie *Total* con la función `auto.arima()`, nos aconseja un modelo $ARIMA(1,1,2)(0,0,1)[52]$ con *drift*, es decir, nos recomienda un modelo $ARIMA(1,1,2)$ con *drift* para la componente no estacional y un modelo $SARIMA(0,0,1)[52]$ para la componente estacional, con los coeficientes de la Tabla II, los cuales podemos observar que son todos significativos y un $AIC=4787.75$ para el modelo.

Haciendo un estudio de los residuos, obtenemos en el *Ljung-box test* un p -valor de 0.1076 por lo que no podemos rechazar la hipótesis nula de que los residuos son independientes. No obstante, el *shapiro-wilks test* obtenemos un p -valor de 4.297×10^{-5} por tanto descartamos que se distribuyan de forma normal. Haciendo un `checkresiduals`, vemos en la Figura 10 que los residuos no parecen ruido blanco, ya que en la ACF parecen correlacionados y en su *plot* parecen no tener varianza constante. Por tanto según en *Ljung-box test* son ruido blanco pero no cualitativamente, por tanto no lo consideramos un modelo adecuado (seguramente tenemos que modelar la varianza, ya que no parece constante).




FIG. 10: Estudio de los residuos del modelo dado por `auto.arima()`

C. Ajuste de un modelo introduciendo la variable C como variable explicativa.

Hagamos ahora lo mismo pero añadiendo el regresor C . De esta manera, obtenemos el modelo $ARIMA(2,0,2)(0,0,1)[52]$ con *intercept* y el regresor y los coeficientes de la Tabla III. En este caso, obtenemos un $AIC=4752.28$, pero no todos los coeficientes son significativos. Por lo que ajustamos el modelo pero fijando el coeficiente $ar1=0$. De esta forma, obtenemos el mismo modelo, esta vez con los coeficientes de la Tabla IV que son todos significativos y un $AIC= 4749.41$. Por lo que a priori, este modelo debería ser mejor que el estimado sin la variable regresora C , por lo que la aportación de la variable regresora C es significativa.

D. Predicción y bondad de ajuste para 2023 con el modelo creado a partir de la serie Total

Si hacemos las predicciones para el año 2023 con el modelo $\text{ARIMA}(1,1,2)(0,0,1)$ [52] con *drift*, obtenemos las estimaciones de la Tabla V. En la Figura 11 podemos ver la serie Total junto a las predicciones para 2023 y en la Figura 12 podemos ver los valores predichos para 2023, junto a los valores reales y el intervalo de confianza 95% de predicción. Notamos que el 100% de los valores están dentro del intervalo de confianza 95%, por lo que a pesar de no parecer un buen modelo, predice bien nuestra serie.

Observemos también que si nos fijamos en los datos reales de las muertes en Palencia en 2023 hasta la semana 44, se han estabilizado bastante las medias, debido seguramente a que ya nadie (o prácticamente nadie) muere por *C* o enfermedades fuera de las habituales (Si hubieramos hecho el modelo entrenado del 2000 al 2019, no hubiera predicho los datos del 2020-21 o incluso 22, donde aún se ve el reflejo de la última ola). [2]




FIG. 11: Serie Total junto a las predicciones para 2023 dadas por el modelo $\text{ARIMA}(1,1,2)(0,0,1)$ [52] con *drift*.




FIG. 12: Predicciones para 2023 junto a intervalo de confianza 95% dados por el modelo $\text{ARIMA}(1,1,2)(0,0,1)$ [52] con *drift* y junto a los datos reales

V. ANÁLISI DE LOS RESIDUOS

Estudiemos ahora los residuos y los residuos al cuadrado del modelo. En la Figura 13 ya podemos observar la

gráfica y la ACF de los residuos, por tanto es suficiente que estudiemos la PACF de los residuos y los residuos al cuadrado. Como podemos observar tanto en la Figura 10 como en la Figura 13, no se ajustan a ser la ACF y PACF de un ruido blanco. Además, en las Figuras 14 y 15 se ve claramente como la varianza de los residuos al cuadrado no es constante y su ACF y PACF no se ajustan a ruido blanco de nuevo. Por tanto, la estructura GARCH en los residuos de estos datos parece razonable.




FIG. 13: PACF de los residuos de la serie Total.




FIG. 14: Cuadrados de los residuos de la serie Total.




FIG. 15: ACF y PACF del cuadrado de los residuos de la serie Total.

VI. AJUSTE DE UN MODELO GARCH

Por último, ajustamos los modelos $\text{GARCH}(1,0)$, $\text{GARCH}(1,1)$, $\text{GARCH}(2,1)$ a la serie Total. Obtenemos los AIC de la Tabla VIa, por tanto, nos quedamos con el modelo $\text{GARCH}(1,1)$ con Ecuación 3.

$$\begin{cases} \text{Defunciones en semana } t = 39.45 + \sigma_t \epsilon_t \\ \sigma_t^2 = 22.6789 + 0.403\epsilon_{t-1}^2 + 0.338\sigma_{t-1}^2 \end{cases} \quad (3)$$

donde $\epsilon_t \sim WN(0,1)$.

VII. CONCLUSIONES

No obstante, los 3 modelos GARCH muestran peores AIC que los dos primeros modelos que hemos estimado. Estudiemos estos dos.

Si hacemos las predicciones con el modelo con la variable C , como podemos ver en la Figura 16, en las predicciones para 2023 junto al intervalo de confianza 95% y los datos reales que obtenemos con el modelo, vemos como hay al menos uno de los valores que no pertenece al intervalo de confianza. Si calculamos el $RMSE$ y R^2 de ambos modelos, como podemos ver en la Tabla VIb, ambos coeficientes R^2 son negativos, lo que quiere decir que la media predice mejor que los modelos. Observando la Figura 16 o 11 notamos que las predicciones van por encima de gran parte de los datos, lo que indica este suceso. En definitiva, de los 5 modelos estudiados, el modelo $ARIMA(2,0,2)(0,0,1)$ [52] con *intercept* y variable de regresión C , es el mejor modelo para predecir nuestros datos, ya que a pesar de predecir una observación fuera del intervalo de confianza, es el que tiene mejores métricas y mejor ajusta los datos.




FIG. 16: Predicciones para 2023 junto al intervalo de confianza 95% y los datos reales obtenidos con el modelo $ARIMA(2,0,2)(0,0,1)$ [52] con *intercept* y variable de regresión C .

VIII. ANEXOS

A. Tablas de coeficientes y p -valores.

1. Modelo $ARIMA(1,1,2)(0,0,1)$ [52] con *drift*

Término	ar1	ma1
Coefficiente	-0.9075	0.2380
p -valor	$< 2.2 \times 10^{-16}$	2.47×10^{-5}
Término	ma2	sma1
Coefficiente	-0.6547	0.1094
p -valor	$< 2.2 \times 10^{-16}$	0.004

TABLE II: Coeficientes del modelo junto a sus p -valores obtenidos haciendo el *test* para ver si son distintos de 0.

2. Modelo $ARIMA(2,0,2)(0,0,1)$ [52] con *intercept* y regresor C

Términi	ar1	ar2	ma1
Coefficiente	-0.086853	0.772852	0.388345
p -valor	0.170798	$< 2.2 \times 10^{-16}$	4.22×10^{-8}
Términi	ma2	sma1	C
Coefficiente	-0.525728	0.107998	6.570579
p -valor	$< 2.2 \times 10^{-16}$	0.004209	0.004715

TABLE III: Coeficientes del modelo junto a los p -valores.

Términi	ar2	ma1	ma2
Coefficiente	0.717255	0.388345	-0.525728
p -valor	$< 2.2 \times 10^{-16}$	$< 2.2 \times 10^{-16}$	$< 4.63 \times 10^{-11}$
Términi	sma1	C	
Coefficiente	0.107998	6.570579	
p -valor	0.004864	0.004860	

TABLE IV: Coeficientes del modelo anterior fijando $ar1=0$, junto a los p -valores.

B. Predicciones para el año 2023 con el modelo $ARIMA(1,1,2)(0,0,1)$ [52] con *drift*.

S01	S02	S03	S04	S05	S06	S07	S08	S09	S10	S11	S12	S13
45.2	45.2	45.7	46.2	45.7	44.9	45.8	44.4	45.4	43.9	45.0	43.5	45.2
S14	S15	S16	S17	S18	S19	S20	S21	S22	S23	S24	S25	S26
45.8	44.8	44.6	45.6	43.1	45.5	45.3	45.1	44.9	44.1	46.9	44.4	44.6
S27	S28	S29	S30	S31	S32	S33	S34	S35	S36	S37	S38	S39
46.5	48.5	49.7	45.3	45.3	45.0	46.1	44.1	44.2	45.4	44.3	45.0	44.6
S40	S41	S42	S43	S44	S45	S46	S47	S48	S49	S50	S51	S52
44.1	45.8	44.5	44.7	45.4	45.3	43.0	45.6	46.0	45.2	43.7	45.6	45.9

TABLE V: Predicción para las defunciones de 2023.

C. Tablas comparativas de métricas entre modelos.

Modelo	AIC
ARCH(1)	6962.990
GARCH(1,1)	6961.897
GARCH(2,1)	6987.470

(a) AIC para cada uno de los 3 modelos GARCH ajustados

Métrica	Modelo 1	Modelo 2
AIC	4787.75	4749.41
RMSE	11.423857	9.232847
R^2	-0.9378637	-0.2658115

(b) Comparación de las métricas entre los modelos considerando y sin considerar la variable regresiva C .

TABLE VI: Tablas comparativas de métricas entre modelos.

D. Código

```

1 #Librerías
2 library(forecast); library(lmtest); library(TSA)
3 library(fGarch); library(tseries);
4 library(tidyverse); library(dplyr)
5
6 ## LECTURA DE LAS DADES
7 setwd("C:/Users/ERIC/Desktop/5. SERIES
  TEMPORALES/PR CTICAS/LLIURAMENT 2")
8 Palencia <- read.table("Palencia.csv", header=T)
  ; head(Palencia)
9
10 ## PRE-PROCESADO
11 Palencia <- Palencia %>% dplyr::select(Periodo,
  Total.1)
12 cat("El total de valores faltantes de Total.1 es
  ", sum(is.na(Palencia$Total.1)))
13
14 ## SEMANAS POR AÑO
15 semanas_per_any <- c(1, rep(0, 23)) #Ponemos la
  primera de 2023
16 a = 1
17 ano = 2000
18 for (i in 2:length(Palencia$Periodo)){
19   if(substr(Palencia$Periodo[i], 1, 4)==substr(
  Palencia$Periodo[i-1], 1, 4)){
20     semanas_per_any[a]=semanas_per_any[a]+1
21   } else{
22     a=a+1
23     semanas_per_any[a]=semanas_per_any[a]+1}
24   for (i in 1:length(semanas_per_any)){
25     cat("El año ", ano+(i-1), "tiene ", semanas_
  per_any[i], "semanas \n")
26   }
27 ## DEFINICIÓN SERIE 'TOTAL'
28 Palencia <- as.data.frame(lapply(Palencia, rev))
29 files_a_excluir = c(261, 522, 835, 1096,
  1201:1244)
30 Total <- Palencia[-files_a_excluir,]
31 nrow(Total)
32
33 Total <- ts(Total$Total.1[521:(sum(semanas_per_
  any))], frequency=52, start=c(2010,01), end=
  c(2022,52))
34
35 ## PLOT SERIE TOTAL
36 plot(Total, ylab="Defunciones", xlab="Semanas",
  main="Defunciones por semana en Palencia
  entre 2010 y 2022")
37 abline(h=mean(Total), col="red", lwd=2)
38 lines(ma(Total, order = 52, centre = T), col="
  blue", lwd=2)
39 legend('topleft', legend=c('Serie 'Total'',
  'Media', 'Media Móvil'), col=c('black','red'
  , 'blue'), lty=c(1, 1,1), lwd=c(1,1.5, 1.5),
  cex=1)
40 mean(Total)
41
42 ## REGRESIÓN 'TOTAL' RESPECTO EL TIEMPO
43 t <- 1:(length(Total))
44 total.lm <- lm(Total ~ t)
45
46 ## TEST COEFICIENTES DE REGRESIÓN
47 coeftest(total.lm)
48
49 ## BOX-PLOT SERIE 'TOTAL'
50 matrix_data_t=t(matrix(data=Total, nrow=52))
51 boxplot(matrix_data_t)

```

```

52
53 ## PRUEBA ESTACIONALIDAD LIKELIHOOD
54 fit1 <- ets(as.vector(Total))
55 fit2 <- ets(as.vector(Total), model="AZN")
56 deviance <- 2*c(logLik(fit1) - logLik(fit2))
57 df <- attributes(logLik(fit1))$df - attributes(
  logLik(fit2))$df
58 #P value
59 1-pchisq(deviance,df) H0: No es estacional / H1:
  es estacional
60
61 ## ESTACIONALIDAD (DECOMPOSE())
62 plot(decompose(Total)$seasonal, ylab="
  Estacionalidad en las Defunciones", xlab="
  Semanas", main="Componente estacional de la
  serie 'Total'")
63
64 ## DEFINICIÓN SERIE 'TOTAL_DIFF1_52'
65 Total_diff1_52 <- diff(diff(Total), lag=52)
66
67 ## PLOT SERIE 'TOTAL_DIFF1_52'
68 plot.ts(Total_diff1_52, ylab="Diferencia de
  Defunciones", xlab="Semanas", main="
  Diferencias de orden 1 y posteriormente 52
  de \n las Defunciones por semana en Palencia
  entre 2010 y 2022")
69 abline(h=mean(Total_diff1_52), col="red", lwd=2)
70 lines(ma(Total_diff1_52, order = 52, centre = T)
  , col="blue", lwd=2)
71 legend('topleft', legend=c('Serie 'Total_diff1_
  52'', 'Media', 'Media Móvil'), col=c('black'
  , 'red', 'blue'), lty=c(1, 1,1), lwd=c(1,1.5,
  1.5), cex=1)
72
73 ## BOX-PLOT SERIE 'TOTAL_DIFF1_52'
74 matrix_data_t=t(matrix(data=Total_diff1_52, nrow
  =52))
75 boxplot(matrix_data_t)
76
77 ## PRUEBA ESTACIONALIDAD LIKELIHOOD
78 fit1 <- ets(as.vector(Total_diff1_52))
79 fit2 <- ets(as.vector(Total_diff1_52), model="
  AZN")
80 deviance <- 2*c(logLik(fit1) - logLik(fit2))
81 df <- attributes(logLik(fit1))$df - attributes(
  logLik(fit2))$df
82 #P value
83 1-pchisq(deviance,df)
84
85 ## ESTACIONALIDAD (DECOMPOSE())
86 plot(decompose(Total_diff1_52)$seasonal, ylab="
  Estacionalidad en las Diferencias de
  Defunciones", xlab="Semanas", main="
  Componente estacional de la serie 'Total_
  diff1_52'")
87
88 ## TEST AUGMENTED DICKEY FULLER A SERIE 'TOTAL_
  DIFF1_52'
89 adf.test(Total_diff1_52)
90
91 ## EACF, ACF, PACF 'TOTAL_DIFF1_52'
92 eacf(Total_diff1_52)
93 par(mfrow=c(2,1))
94 acf(Total_diff1_52)
95 pacf(Total_diff1_52, main="")
96 par(mfrow=c(1,1))
97
98 ## MODELO auto.arima() PARA LA SERIE 'TOTAL'
99 mod1 <- auto.arima(Total)
100

```



```

101 ## TEST PARA LOS COEFICIENTES DEL MODELO
102 coeftest(mod1)
103
104 ## ESTUDIO DE LOS RESIDUOS PARA EL MODELO
105 checkresiduals(mod1)
106
107 ## SHAPIRO WILK TEST PARA LOS RESIDUOS
108 shapiro.test(mod1$residuals)
109
110 ## PREDICCIONES 2023 CON EL MODELO
111 pred1 <- forecast(mod1, h=52)
112
113 ## DEFINICI N DE LOS DATOS DE DEFUNCI N 2023
114 real <- ts(tail(Palencia,44)$Total.1, frequency
115 =52, start=c(2023,01), end=c(2023,44))
116
117 ## VISUALIZAMOS LA PREDICCI N
118 plot(pred1, xlab="Semanas", ylab="Defunciones",
119 main="Predicciones del modelo ARIMA(1,1,2)
120 (0,0,1)[52] \n con drift para 2023")
121
122 plot(pred1$mean, type='l', lwd=2, col='blue',
123 xlab='Semanas', ylab='Valores Predichos con
124 IC', main='Valores Predichos con Intervalos
125 de Confianza', ylim=c(0, 100))
126 lines(pred1$lower[,2], col='black', lty=3, lwd
127 =2)
128 lines(pred1$upper[,2], col='black', lty=3, lwd
129 =2)
130 lines(real, col='red', lwd=2)
131 legend('topleft', legend=c('Valores Reales',
132 'Valores Predichos', 'Intervalo de Confianza'
133 ), col=c('red', 'blue', 'gray'), lty=c(1,
134 1,2), lwd=c(2,2, 1), cex=0.8)
135
136 ## ESTUDIO DE LOS RESIDUOS (continuaci n)
137
138 pacf(mod1$residuals)
139
140 plot((mod1$residuals)^2, ylab="Residuos al
141 cuadrado", xlab="Semanas")
142 par(mfrow=c(2,1))
143 acf((mod1$residuals)^2, main="Serie Residuos al
144 Cuadrado")
145 pacf((mod1$residuals)^2, main="")
146
147 par(mfrow=c(1,1))
148
149 ## MODELOS GARCH
150 mod3 <- garch(Total, order=c(0, 1))
151 mod4 <- garch(Total, order=c(1, 1))
152 mod5 <- garch(Total, order=c(1, 2))
153
154 ## AIC de los modelos
155 c(AIC(mod3), AIC(mod4), AIC(mod5))
156
157 ## MEJOR MODELO GARCH
158 mod4 <- garchFit(~garch(1,1), Total)
159 coef(mod4)
160
161 ## AJUSTE A ADIENDO REGRESOR COVID
162 COVID<-c(rep(0,531), rep(1,93), rep(0,52))
163
164 ## REGRESI N 'TOTAL' RESPECTO A 'COVID'
165 Total.lm2 <- lm(Total~COVID)
166
167 ## TEST PARA LOS COEFICIENTES DEL MODELO
168 coeftest(Total.lm2)
169
170 ## MODELO auto.arima() A ADIENDO EL REGRESOR
171 COVID
172 mod_cov <- auto.arima(Total, xreg=COVID)
173
174 ## TEST PARA LOS COEFICIENTES DEL MODELO
175 coeftest(mod_cov)
176
177 ## FIJAMOS QUE EL COEFICIENTE ar1 SEA 0
178 mod_cov <- arima(Total, order=c(2,0,2), seasonal
179 =list(order=c(0,0,1), period=52), xreg=COVID
180 , include.mean=TRUE, fixed=c(0, NA, NA, NA,
181 NA, NA, NA))
182
183 ## TEST PARA LOS COEFICIENTES DEL MODELO
184 coeftest(mod_cov)
185
186 ## ESTUDIAMOS LOS RESIDUOS
187 checkresiduals(mod_cov)
188
189 ## PREICCIONES 2023
190 pred2 <- forecast(mod_cov, h = 52, xreg=numeric
191 (52))
192
193 ## PLOT BONDAD DE AJUSTE
194 plot(pred2$mean, type='l', lwd=2, col='blue',
195 xlab='Semanas', ylab='Valores Predichos con
196 IC', main='Valores Predichos con Intervalos
197 de Confianza', ylim=c(0, 100))
198 lines(pred2$lower[,2], col='black', lty=3, lwd
199 =2)
200 lines(pred2$upper[,2], col='black', lty=3, lwd
201 =2)
202 lines(real, col='red', lwd=2)
203 legend('topleft', legend=c('Valores Reales',
204 'Valores Predichos', 'Intervalo de Confianza'
205 ), col=c('red', 'blue', 'gray'), lty=c(1,
206 1,2), lwd=c(2,2, 1), cex=0.8)
207
208 ## RMSE DE LOS DOS MODELOS ARIMA
209 rmse1 = sqrt(mean(((pred1$mean)[1:44] - real)^2)
210 )
211 rmse2 = sqrt(mean(((pred2$mean)[1:44] - real)^2)
212 )
213 c(rmse1, rmse2)
214
215 ## C LCULO DEL R2 DE LOS DOS MODELOS ARIMA
216 SSR1 = sum(((pred1$mean)[1:44] - real)^2)
217 SST1 = sum((mean(real)-real)^2)
218 SSR2 = sum(((pred2$mean)[1:44] - real)^2)
219
220 c(1- SSR1/SST1, 1- SSR2/SST1)

```

[1] Estimaci3n del n3mero de defunciones semanales de por provincia (2000-).

[2] La oms decreta el fin de la emergencia internacional por la covid (2023).